

Tarea 1 — Introducción a la Ciencia de Datos

2026
Grupo 12
Germán Astol
Santiago Tucci

1. Introducción

Este informe presenta el análisis exploratorio de un subconjunto del dataset *All the News 2.1 – Component One*, que reúne artículos publicados en distintos medios de prensa anglosajones. El trabajo está organizado en dos partes: la primera abarca la carga, inspección y limpieza de los datos; la segunda, el análisis de frecuencia de palabras y la generación de visualizaciones comparativas.

El procesamiento se realizó en Python utilizando pandas, a partir del notebook provisto. Para enfocar el estudio en los casos más representativos, se seleccionaron los cinco medios con mayor cantidad de artículos en el dataset.

2. Carga y calidad de datos

2.1 Verificación inicial

Tras ejecutar las primeras celdas del notebook, se verificó la correcta carga de los *DataFrames*. Se realizó una inspección inicial con `.head()`, `.info()` y `.isnull().sum()` para tener una primera lectura del contenido y detectar posibles problemas.

2.2 Problemas de calidad detectados

Complejidad

Se identificaron valores faltantes en varias columnas:

Campo	% de valores faltantes
article (cuerpo)	3,9%
author	37,7%
url	0,5%
section	33,9%
publication	0,5%

Tabla 1: Porcentaje de valores faltantes por columna.

El alto porcentaje de valores faltantes en *author* y *section* no afecta directamente el análisis de contenido, pero sí limita la posibilidad de estratificar por autor o sección temática en etapas posteriores.

Exactitud sintáctica

La columna *date* presenta dos formatos distintos: el 64,3% de los registros incluye fecha y hora, mientras que el 35,7% restante contiene únicamente la fecha. Esto no genera inconsistencias en el análisis temporal siempre que se normalice el campo al extraer la fecha. Adicionalmente, el *DataFrame* incluye las columnas *year*, *month* y *day*, que son redundantes con la información contenida en *date*, por lo que se eliminaron para simplificar la estructura.

Exactitud semántica

El 3,9% de los artículos en la columna *article* presentan menos de 20 caracteres, lo que en la práctica equivale a contenido vacío o inválido. Ejemplos como "Book review of" sugieren que se trata de entradas incompletas o errores de carga. Estos registros fueron excluidos del análisis.

Unicidad

Se detectaron 13 registros con título, cuerpo y medio de publicación idénticos pero con URLs distintas, lo que indica duplicados reales en el dataset. Dado que la URL no fue suficiente para distinguirlos semánticamente, se eliminó uno de cada par duplicado tomando como criterio la combinación *title* + *article* + *publication*.

2.3 Selección de medios principales

Se realizó un conteo de artículos por medio de prensa y se seleccionaron los cinco con mayor volumen. Estos son los que se utilizan en el resto del análisis.

Medio	Cantidad de artículos
Reuters	9.424
The New York Times	2.834
CNBC	2.601
The Hill	2.349
People	1.528

Tabla 2: Artículos por medio de prensa (top 5).

3. Análisis temporal

Se generó una visualización de la cantidad mensual de artículos publicados por cada uno de los cinco medios seleccionados a lo largo del período cubierto por el dataset (2016–2020). Dado que Reuters presenta un volumen notablemente superior al resto, se graficó cada medio en un panel separado para facilitar la comparación de patrones individuales (Figura 1).




Figura 1: Cantidad mensual de artículos por medio, 2016–2020.

Observaciones por medio

CNBC

CNBC muestra un crecimiento sostenido desde aproximadamente 30 artículos mensuales en 2016 hasta cerca de 100 en 2019–2020, con un quiebre visible hacia mediados de 2019. Este salto coincide con la intensificación del ciclo noticioso político-económico durante la presidencia de Trump: las tensiones comerciales con China y el proceso de juicio político (impeachment) iniciado en septiembre de 2019 ampliaron significativamente la demanda de

cobertura financiera y política. La caída abrupta al final de la serie refleja el límite temporal del dataset, no una contracción real del medio.

People

People mantiene un volumen estable de aproximadamente 30 artículos mensuales a lo largo de todo el período, lo cual es consistente con el ritmo editorial de una revista de entretenimiento con agenda más previsible que la de un medio de noticias. La caída pronunciada al final de la serie coincide con el impacto de la pandemia de COVID-19 sobre la industria de medios: la cancelación de eventos presenciales y el desplome de la publicidad afectaron de manera especialmente severa a revistas y publicaciones impresas .

Reuters

Reuters presenta el mayor volumen del conjunto, con entre 100 y 250 artículos mensuales durante la mayor parte del período. Este nivel es esperable para una agencia de wire con cobertura global que actúa como proveedora de contenido para cientos de medios. El pico excepcional registrado a principios de 2020, que supera los 400 artículos en un mes, corresponde a la explosión informativa provocada por el COVID-19: según la firma de analítica NewsWhip, la pandemia generó más de 1,5 millones de artículos desde enero de 2020, a un ritmo de cerca de 1.400 por día.

The Hill

The Hill exhibe el comportamiento más estable del conjunto, con una producción sostenida de entre 40 y 55 artículos mensuales durante todo el período. Al estar especializado en política del Congreso y Washington D.C., su agenda editorial es menos reactiva a shocks externos que los medios de economía o entretenimiento. La ligera baja al final de la serie es coherente con los recortes generalizados que vivió la industria periodística en 2020.

The New York Times

El New York Times muestra una tendencia levemente decreciente: parte de alrededor de 80 artículos mensuales en 2016 y converge hacia unos 55 hacia el final del período. Esta reducción en volumen no refleja un deterioro editorial sino una reorientación estratégica: el NYT fue uno de los pocos grandes medios que salió fortalecido de la crisis de 2020, con crecimiento sostenido en suscriptores digitales. La caída gradual en cantidad de artículos en el dataset es consistente con una apuesta por contenido más profundo y diferenciado frente al modelo de alta frecuencia.

4. Limpieza y normalización del texto

Para poder realizar conteo de palabras de forma consistente, es necesario normalizar el texto antes de procesarlo. La función `clean_text()` fue extendida con respecto a su versión original para lograr una limpieza más robusta y completa.

4.1 Comparación entre versiones

La versión original de la función eliminaba signos de puntuación de forma manual, iterando sobre una lista fija de caracteres:

```
for punc in ["", "\n", ",", ":", "?"]:  
    result = result.str.replace(punc, " ")
```

Este enfoque tiene dos problemas: es incompleto (deja pasar puntos, comillas, paréntesis, números, guiones, entre otros) y es frágil (requiere recordar agregar cada carácter manualmente). La versión actualizada reemplaza ese bloque por una expresión regular que invierte la lógica: en lugar de enumerar lo que se quiere eliminar, conserva únicamente letras minúsculas y espacios, descartando todo lo demás en una sola operación:

```
result = result.str.replace(r'^[a-z\s]', ' ', regex=True)
```

Esto garantiza que números, signos de puntuación, caracteres Unicode, URLs y cualquier otro símbolo queden eliminados sin necesidad de enumerarlos explícitamente.

4.2 Transformaciones aplicadas

La función final aplica las siguientes transformaciones, en orden:

Transformación	Justificación
Conversión a string con <code>.astype('string')</code>	Evita errores cuando el campo contiene valores nulos o de tipo mixto.
Eliminación del encabezado (primera línea hasta <code>\n</code>)	Los artículos de Reuters y otros medios suelen comenzar con una línea de encabezado del tipo 'Feb 2 (Reuters) -' que no forma parte del contenido editorial.
Conversión a minúsculas	Unifica variantes como 'President' y 'president' para que se contabilicen como la misma palabra.
Eliminación de todo lo que no sea letra o espacio (<code>[^a-z\s]</code>)	Elimina signos de puntuación, números, URLs, símbolos y caracteres especiales en una sola operación.
Normalización de espacios múltiples (<code>\s+</code>)	Colapsa secuencias de espacios o saltos de línea en un único espacio, dejando el texto limpio para tokenizar.

Tabla 3: Transformaciones aplicadas en `clean_text()`.

4.3 Ejemplo

El siguiente ejemplo ilustra el efecto de la limpieza sobre un artículo real del dataset:

Antes:

```
Feb 2 (Reuters) - Teva Pharmaceutical Industries Ltd : * EUROPEAN
MEDICINES AGENCY (EMA) ACCEPTS FREMANEZUMAB MARKETING AUTHORIZATION
APPLICATION Source text for Eikon: Further company coverage:
```

Después:

```
teva pharmaceutical industries ltd european medicines agency ema accepts
fremanezumab marketing authorization application source text for eikon
further company coverage
```

Se puede observar que el encabezado con la fecha y la fuente ('Feb 2 (Reuters) -') fue eliminado, el texto quedó en minúsculas y se removieron los dos puntos, paréntesis y asteriscos. El resultado es un texto "tokenizable" directamente por espacios.

5. Selección del campo de texto: título, cuerpo o combinación

Una decisión que afecta tanto la calidad del análisis de frecuencia como cualquier tarea de clasificación posterior es elegir sobre qué campo de texto trabajar. Se evaluaron tres alternativas.

Solo el título

El título es breve y suele estar redactado para capturar la idea central del artículo. Tiene la ventaja de que es más uniforme en longitud y tiende a evitar el ruido lingüístico (texto boilerplate, frases de relleno, fórmulas repetidas). Sin embargo, su brevedad implica muy poco vocabulario por artículo, lo que dificulta cualquier análisis basado en frecuencias o representaciones vectoriales.

Solo el cuerpo

El cuerpo del artículo contiene la mayor parte de la información y ofrece mucho más contexto léxico. Es el campo más rico para análisis de contenido. La desventaja es que es más ruidoso: incluye texto repetido entre artículos del mismo medio (firmas, disclaimers, fórmulas de cierre), lo que puede introducir sesgo en el análisis si no se trata con cuidado.

Combinación de título y cuerpo

Concatenar título y cuerpo permite aprovechar la complementariedad de ambos: el título aporta las palabras clave más representativas del artículo, mientras que el cuerpo provee el contexto necesario para un análisis más completo. Esta combinación también tiene una ventaja práctica en el contexto de este dataset: dado que ya se detectaron duplicados por coincidencia de título y cuerpo, normalizar ambas columnas conjuntamente permite identificar posibles duplicados adicionales que no hubieran sido detectados revisando cada campo por separado.

Decisión

Se opta por trabajar con la combinación de título y cuerpo. Esta elección maximiza la información disponible por artículo y es la más adecuada tanto para el análisis exploratorio de frecuencias como para una eventual tarea de clasificación por medio de prensa. A nivel análisis de contenido el cuerpo domina, pero la normalización del título puede mejorar la unicidad de los datos.

6. Identificadores de medio

Se analizan la presencia del nombre de medio de prensa, URL, autores, secciones y plantillas en la columna article, a modo de ver si el mismo puede permitir identificar al medio.

Medio	Presencia(%)
The Hill	99,4
Reuters	88,6
People	68,1
CNBC	34,6
The New York Times	22,8

Tabla 4: Porcentaje de presencia del nombre en artículo.

Autores

El 9,1% de los artículos contienen una firma de su autor en el cuerpo. Sin embargo, pese a ser una pista, no es distintivo ya que varios autores tienen artículos de diferentes medios, ejemplificando: Jennifer Calfas tiene publicaciones en "The Hill" y "People"

Sección

El 13,9% de los artículos contienen el nombre de la sección en el cuerpo. Sin embargo, pese a ser una pista, no es distintivo ya que varias secciones están presentes en varios medios, ejemplificando: "Health" es una sección en "People" y en "The New York Times"

Plantillas repetidas

Se identificaron fragmentos repetidos al inicio de múltiples artículos, especialmente en Reuters, The Hill y The New York Times. Estas repeticiones corresponden a plantillas editoriales o encabezados automáticos del medio, por ejemplo: "View the discussion thread" (The Hill) o "Times Insider delivers behind-the-scenes insights..." (The New York Times). Dado que estas frases identifican directamente al medio, se recomienda eliminarlas o incorporarlas como stopwords adicionales antes de entrenar cualquier clasificador, de lo contrario el modelo puede aprender a reconocer el medio por su plantilla en lugar de por su estilo editorial.

URL

Usando la biblioteca *urlparse* sobre la columna *url*, se extrajeron los dominios de los artículos. Se encontró que el 56,5% de los artículos contiene la URL del medio en el cuerpo del texto. El caso más extremo es Reuters, donde el 88,6% de sus artículos incluye la URL *www.reuters.com* en el cuerpo. En el otro extremo, The Hill la incluye en apenas el 1,9% de sus artículos. La presencia de URLs es una pista directa del medio y debería eliminarse del texto antes de cualquier tarea de clasificación.

7. Restricción por sección o período temporal

Una posibilidad a considerar para futuras tareas de clasificación es limitar el análisis a artículos de una misma sección temática o de un período acotado. La motivación es simple: si los medios cubren distintas proporciones de política, economía o entretenimiento, un clasificador podría estar aprendiendo a distinguir temas antes que medios. Restringir el corpus a una sola sección, o a un período donde todos los medios cubran los mismos eventos, reduciría esa fuente de confusión.

La principal ventaja es que hace más justa la comparación entre medios: se controla el tema y el modelo tiene más chances de capturar diferencias estilísticas reales. La desventaja más concreta es el tamaño del corpus resultante: dado que el 33,9% de los artículos no tiene sección registrada, filtrar por esa columna reduce bastante los datos disponibles. Además, un modelo entrenado en un solo período puede no generalizar bien a otros contextos.

Una desventaja adicional de restringir por período temporal es que algunos medios pueden tener cobertura irregular en ciertos momentos: si un medio tiene pocos artículos en el período seleccionado, el análisis queda desbalanceado. Por otro lado, restringir a una sola sección temática puede eliminar precisamente las diferencias estilísticas más características de cada medio, ya que cada uno tiene su forma propia de cubrir política, economía o entretenimiento. La restricción temática ayuda a controlar el sesgo de contenido pero puede reducir la variabilidad estilística que se quiere capturar.




Figura 4: WordCloud The Hill



Figura 5: WordCloud The New York Times



Figura 6: WordCloud People

Las palabras más frecuentes de cada medio reflejan bien su perfil editorial. Reuters, una vez eliminados los artefactos del encabezado de agencia, queda dominado por términos financieros como *percent*, *million*, *billion* y *company*, lo que es consistente con su rol de proveedor de noticias económicas globales. CNBC muestra un perfil parecido pero con más peso político: *trump*, *china* y *trade* aparecen junto a *percent* y *market*, lo que tiene sentido dado el período cubierto.

The Hill es el caso más llamativo: *trump* domina la wordcloud de forma notoria, muy por encima del resto, y casi todas las palabras del top 10 remiten a política del Congreso (*senate*, *house*, *democrats*, *capitol*, *washington*). The New York Times tiene un vocabulario más repartido, con términos genéricos como *people*, *years* y *state* conviviendo con *trump* y *president*. People es el más diferenciado: palabras como *family*, *love*, *told* y *really* marcan un registro completamente distinto al del resto, propio de una revista de entretenimiento.

Una forma de adaptar la visualización para comparar entre secciones o períodos es aprovechar las stopwords como herramienta de filtrado temático. Por ejemplo, para aislar el efecto de un período específico se podrían agregar a las stopwords términos asociados a ese contexto —como *covid*, *pandemic* o *virus*— y observar cómo cambia el vocabulario restante. De la misma forma, se podrían definir listas de stopwords temáticas para neutralizar categorías enteras: palabras como *senate*, *house* o *democrats* para filtrar contenido político, o *people*, *years* y *state* para contenido más general. Esto permitiría generar wordclouds comparables entre medios sin que el tema domine la visualización, facilitando la identificación de diferencias estilísticas más sutiles.

2. Conteo de palabras por medio

Para el conteo se realiza sobre la columna *article* luego de limpiarse, presentándose los resultados en la Tabla 5.

Medio	Total de Palabras
Reuters	1.780.158
The New York Times	1.661.083
The Hill	934.412
CNBC	822.477
People	398.161

Tabla 5: Cantidad de palabras por medio.

3. Menciones cruzadas entre medios

Recorriendo los artículos buscando el nombre de los medios, se obtiene la siguiente matriz, representada en la Tabla 6.

Medio	Reuters	CNBC	The Hill	NYT	People
Reuters	8352	31	2	29	1505
CNBC	821	899	5	46	811
The Hill	71	13	2335	130	959
The New York Times	45	13	15	482	1588
People	4	3	4	43	1018

Tabla 6: Matriz de menciones.

Vemos claramente que prevalece la mención propia de cada medio en sus artículos por encima de la mención de los medios competidores con excepción del NYT que menciona 3 veces más a su competidor People por encima de las menciones propias.

Algo curioso que sucede con el medio People, es que es el más nombrado, en promedio, por sus competidores, y eso puede deberse a que el término *people* (refiriéndose a personas), es confundido por el nombre del medio (People).

En este caso puede tener sentido realizar una matriz de menciones pero sin convertir a minúsculas todas las palabras ya que de esa manera perderíamos la distinción entre el nombre propio del medio y el término *people* (por personas)

Haciendo este ajuste representado en la Tabla 7, se ve que la cantidad de menciones a People decrece notoriamente, aunque el mismo sigue siendo el que menos se nombra a sí mismo, en comparación a cuanto lo nombran los demás, en términos comparativos.

Medio	Reuters	CNBC	The Hill	NYT	People
Reuters	8716	32	0	9	183
CNBC	820	896	2	30	109
The Hill	71	13	2335	114	76
The New York Times	43	13	4	472	258
People	4	3	4	26	147

Tabla 7: Matriz de menciones case sensitive

Si construimos un grafo dirigido, vemos cómo fluyen las menciones entre medios, se representa en la Figura 7.




Figura 7: Grafo dirigido de menciones

Midiendo el ranking de autoridad de cada medio, que mide no sólo cuántos te mencionan, sino qué tan importantes son los que te mencionan, se obtiene el siguiente resultado presentado en la Figura 8.




Figura 8: PageRank de menciones

Concluimos que Reuters actúa como la fuente primaria de información, ya que su peso es el 40% en este ranking. People recibe menciones de fuentes de muy alta autoridad (como Reuters o el NYT) y, probablemente, al tener menos menciones salientes hacia otros retiene más su "autoridad acumulada". The Hill y NYT están a la par y CNBC es irrelevante en términos relativos.

4. Preguntas propuestas

Después de haber trabajado este dataset, limpiando los datos, y estableciendo relaciones entre medios de prensa y el contenido de los artículos publicados surgen una serie de preguntas que pueden ser contestadas a partir de los datos disponibles:

1. ¿Existe una especialización temática marcada por medio de prensa si logramos reconstruir la información faltante de las secciones?

El camino propuesto para responder la pregunta sería:

Filtrar el data frame original para obtener dos subconjuntos: uno con los registros que tienen la columna *section* completa (conjunto de entrenamiento/test) y otro con los valores nulos (conjunto a predecir). Usando el pre procesamiento de texto en la columna *article* ya realizado, debemos mediante el uso de vectorización de los artículos, usando Word Embeddings, lo convertiremos en representaciones numéricas.

Con esto, podemos entrenar un modelo de clasificación multiclase (por ejemplo, Support Vector Machines o un Naive Bayes Multinomial) utilizando la columna *section* como etiqueta.

Luego debemos validar la precisión del modelo en el conjunto de datos conocidos mediante una matriz de confusión. Por último, aplicaremos el modelo para predecir e imputar los valores nulos en el 33.8% de los datos faltantes.

Con el dataset ahora completo podremos calcular la distribución porcentual de temas por medio para identificar si, por ejemplo, medios como Reuters se inclinan más a "Economía" mientras que otros se concentran en "Política" o "Cultura", confirmando así la especialización editorial.

2. ¿Cómo evolucionó el interés mediático sobre temas específicos (por ejemplo, "Coronavirus" o "Tecnología") a lo largo del tiempo?

Para esto deberíamos filtrar los artículos mediante palabras clave en los títulos y artículos. Una vez aislados esos datos, el siguiente paso sería realizar un análisis de series temporales, agrupando la frecuencia de publicaciones por mes y por año para cada medio de prensa. Esto nos permitiría visualizar "picos" de cobertura y comparar la dinámica de respuesta: por un lado, identificar si agencias con formatos de despachos rápidos, como los *briefs* de Reuters, son las primeras en reaccionar con notas cortas y directas, y por otro, contrastar si medios con una línea más editorial se toman más tiempo para publicar, pero ofreciendo textos más extensos y analíticos.

3. ¿Cómo varía el sesgo político de la cobertura entre medios a lo largo del tiempo?

Se podría abordar construyendo un diccionario de términos asociados a cada orientación política (por ejemplo, palabras frecuentemente usadas en discurso progresista vs conservador) y midiendo la frecuencia relativa de cada grupo por medio y por mes.

Graficando esa evolución temporal se podría ver si los medios mantienen una línea estable o si convergen/divergen en momentos de alta tensión política, como elecciones o el impeachment de 2019.

Declaración de uso de IA

Se utilizó Claude para ordenar el código y para análisis inicial de tendencias temporales que luego fueron buscadas en la web.